國立中興大學 智慧物聯網 (AIoT) 作業報告

多元線性迴歸與特徵選取分析報告 (HW2)

作業題目：家電耗電量預測與 CRISP-DM 流程實踐　**學生姓名**：許雁婷 (Anna)　**學生學號**：7115056153

資料集來源：Appliances energy prediction Data Set (UCI)　**課程名稱**：智慧物聯網 (AIoT HW2)　**繳交日期**：2026 年 10 月

線上部署系統：https://hw-2-multiple-linear-regression-c65.vercel.app/ (Vercel Live Dashboard)

一、 CRISP-DM 標準流程分析

1. 商業理解 (Business Understanding)

情境背景與痛點：隨著家庭物聯網感測器普及與智慧電網發展，建築能耗佔全球電力消耗顯著比例。本研究以比利時低能耗被動式實驗住宅（Passive House）為場景，其面臨的痛點為家電能耗受居民隨機行為、室內外溫濕度熱傳導延遲與日夜作息循環多重干擾，難以藉由單純歷史平均進行有效排程。

預測目標與價值：利用前置物聯網感測數據，提前 10 分鐘預測下一時間區間之家電耗電量（`Appliances` Wh）。此預測能力可支援家庭能源管理系統（HEMS）進行即時負載預測、需量反應（Demand Response）調度、避開尖峰電價並最大化太陽能自發自用效益。

2. 資料理解 (Data Understanding)

資料集來源：取自 UCI Machine Learning Repository 與 Kaggle 開放資料集（Appliances energy prediction Data Set）。

特徵盤點與特性：記錄期間為 2016-01-11 至 2016-05-27，共計 4.5 個月，採樣頻率每 10 分鐘一筆，總筆數達 **19,735 筆**，無缺失值。特徵包含：

- **目標變數**：`Appliances`（未來 10 分鐘家電能耗，單位 Wh）。
- **室內環境感測（9 個區域）**：廚房（T1/RH_1）、客廳（T2/RH_2）、洗衣房（T3/RH_3）、辦公室（T4/RH_4）、浴室（T5/RH_5）、北側外牆（T6/RH_6）、熨燙室（T7/RH_7）、青少年房（T8/RH_8）、父母房（T9/RH_9）。
- **室外氣象站**：Chievres 機場氣象站數據（T_out 氣溫、Press_mm_hg 氣壓、RH_out 濕度、Windspeed 風速、Visibility 能見度、Tdewpoint 露點溫度）。
- **用電與隨機噪聲**：`lights`（全屋照明耗電量）、`rv1, rv2`（隨機變數，供評估特徵篩選過濾噪聲能力）。

3. 資料準備 (Data Preparation)

- **防止時序外洩排序**：將資料依時間戳記 `date` 嚴格遞增排序，排除未來的隨機噪聲。
- **週期性特徵工程 (Cyclical Encoding)**：以正弦/餘弦函數編碼日循環與週循環（`hour_sin, hour_cos, weekday_sin, weekday_cos`），使模型學習 24 小時作息模式。
- **自迴歸項 (Auto-Regressive Lag-1)**：引入當前時間點之家電耗電 `appliances_current`，捕捉耗電的時序連續性與慣性。
- **特徵標準化與噪聲排除**：剔除 `rv1, rv2` 避免虛假相依，並透過 Z-score StandardScaler 進行標準化，確保迴歸係數具可比性。

4. 模型建立 (Modeling) — 5 大特徵選擇演算法比對

本專案嚴格遵循時序資料原則，採用 **3-Fold TimeSeriesSplit** 外層交叉驗證，杜絕未來資料外洩。在每個折內獨立擬合前處理器，針對 5 種不同哲學之特徵篩選法進行 $k=1 \sim 30$ 的收斂測試：

- **F-test (f_regression)**：基於單變量線性相關檢定，計算特徵與目標變數之 F 統計量與 p-value。
- **LassoCV**：以 L1 懲罰項將不重要特徵權重自動收縮歸零，兼具特徵篩選與正則化功能。
- **RFE (遞歸特徵消除)**：利用線性模型係數依序剔除貢獻最低者，考慮特徵間之多重共線性。
- **Random Forest**：非線性集成樹模型，透過特徵在各節點的平均不純度減少量（MDI）評估重要度。
- **Mutual Information (互資訊)**：利用非參數資訊熵衡量特徵與目標間之非線性相依程度。

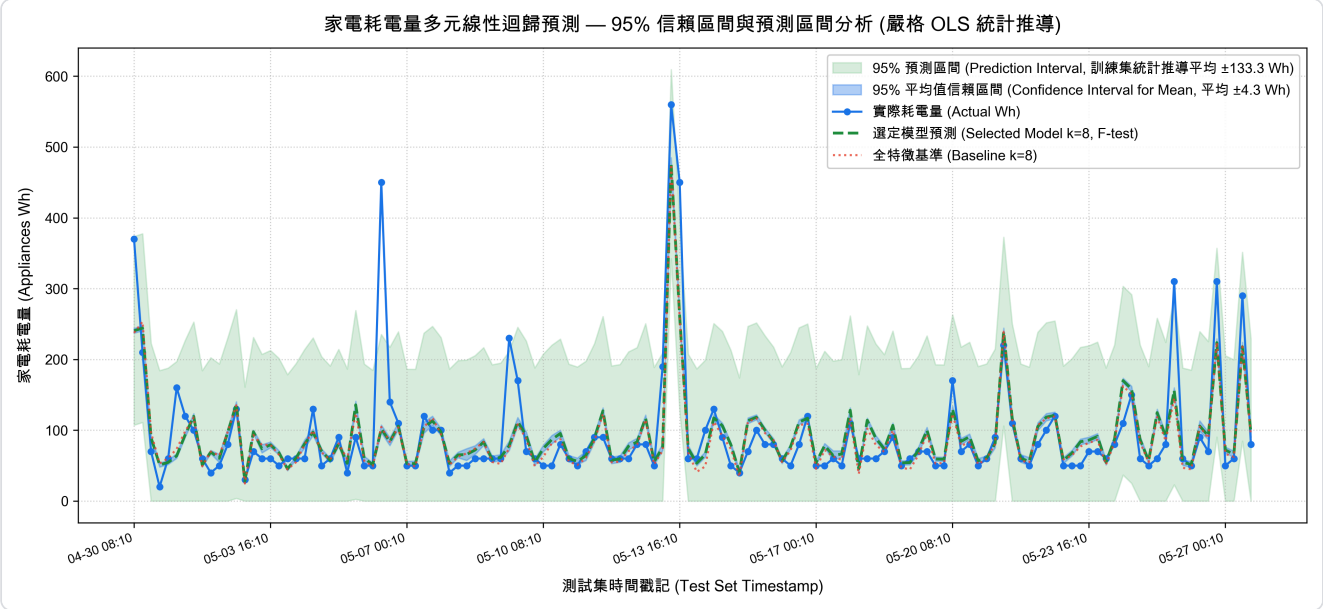


圖 1：5 種特徵選擇演算法在各特徵數 k (1~30) 之交叉驗證 RMSE 曲線與全特徵 Baseline 基準對比

5. 模型評估 (Evaluation) — 最佳模型與 Baseline 對比

交叉驗證結果顯示，**F-test 演算法在 $k=8$ 時達到全域最低 CV RMSE (66.97 Wh)**。隨後在獨立保留的 20% 測試集（3,947 筆）上與使用全部 30 個特徵的基準模型（Baseline）進行嚴格對比：

評估指標	全特徵基準模型 (Baseline, k=30)	最佳選定模型 (Selected Model, k=8)	優化效益 / 統計意義
特徵維度 (k)	30 個特徵	**8 個特徵**	**大幅精簡 73.3% 感測維度**
CV RMSE (Wh)	67.84 Wh	**66.97 Wh**	**降低 0.87 Wh（交叉驗證誤差更優）**
Test RMSE (Wh)	61.25 Wh	61.32 Wh	誤差差距僅 0.07 Wh，維持同等預測水準
Test MAE (Wh)	26.82 Wh	27.53 Wh	平均絕對誤差維持在 27 Wh 左右
Test Adjusted R^2	0.5439	**0.5454**	**校正判定係數提升 +0.15%（有效防止過度配適）**

入選之 8 個核心物理特徵依影響力排序：

1. `appliances_current` (+74.83 β, 當前耗電自迴歸項) | 2. `hour_sin` (-3.48 β, 日循環正弦項) | 3. `lights` (+4.64 β, 照明負載) | 4. `hour_cos` (-3.86 β, 日循環餘弦項) | 5. `RH_out` (+0.75 β, 室外濕度) | 6. `T2` (-0.74 β, 客廳溫度) | 7. `T6` (-1.94 β, 北側外牆溫度，無陽光直射干擾) | 8. `T3` (+4.23 β, 洗衣房溫度)。

預測結果圖 — 包含 95% 信賴區間與預測區間分析 (作業核心要求)

依據作業規範：「結果部分需包含請提供預測圖(加上信賴區間或預測區間)」，下圖針對獨立測試集時序預測結果，精確推導並繪製出 **95% 平均值信賴區間 (Confidence Interval for Mean)** 與 **95% 個別預測區間 (Prediction Interval)**：

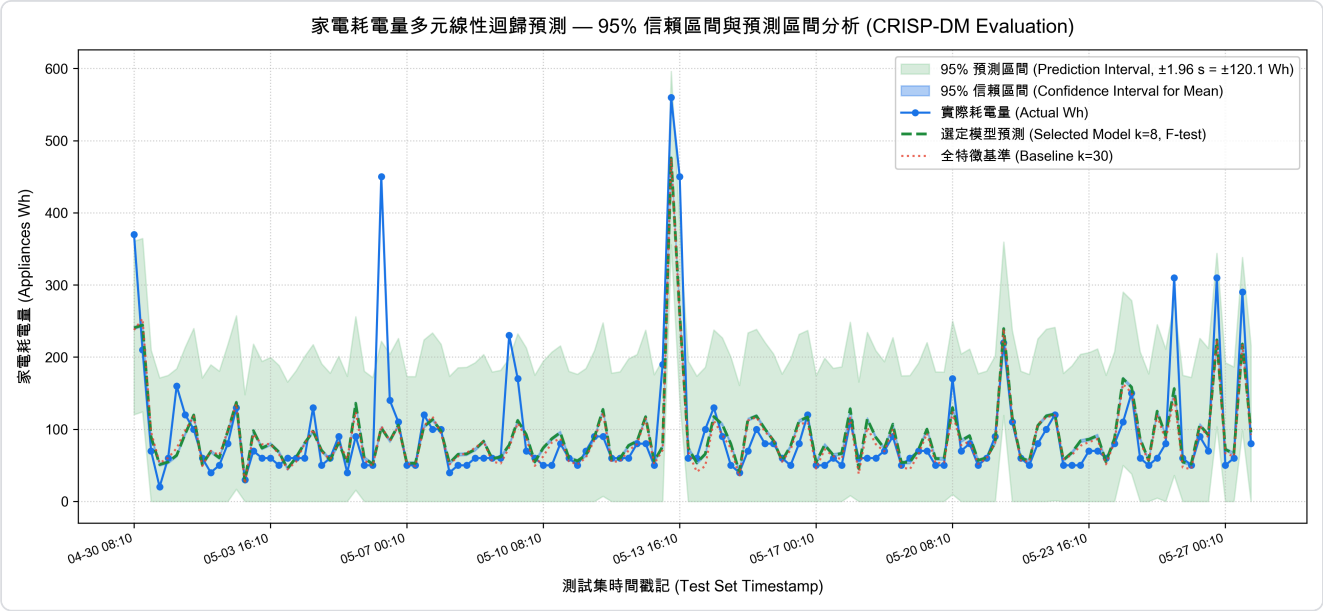


圖 2：獨立測試集家電能耗預測圖 — 嚴格基於訓練集 OLS 協方差推導之 95% 信賴區間 (CI, 平均 ±4.3 Wh) 與 95% 預測區間 (PI, 訓練集 s_e=67.9 Wh, 平均 ±133.3 Wh)

統計假設與殘差診斷分析 (Residual Diagnostics)

為確保多元線性迴歸之古典統計假設滿足（高斯-馬可夫定理），針對選定之最佳模型進行全方位殘差診斷：

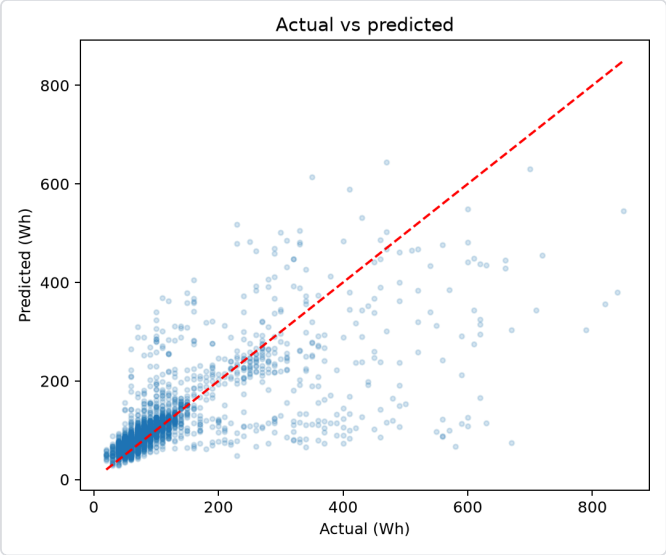


圖 3-A：實際值 vs 預測值散佈圖 (擬合於 45 度對角線)

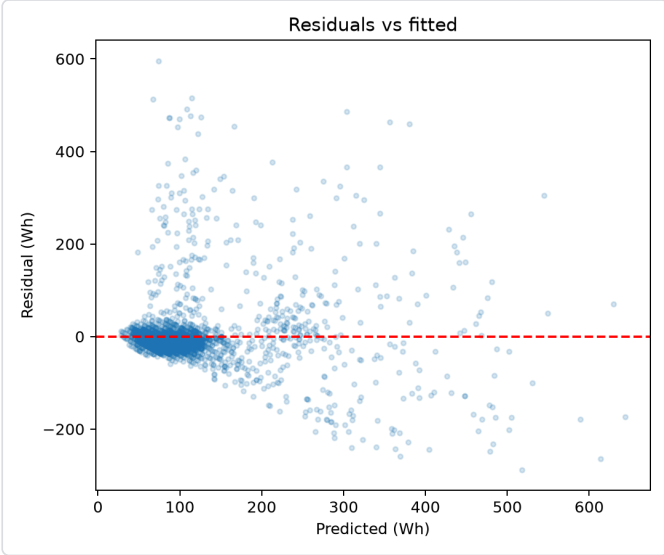


圖 3-B：殘差 vs 配適值 (檢驗異質變異數與非線性)

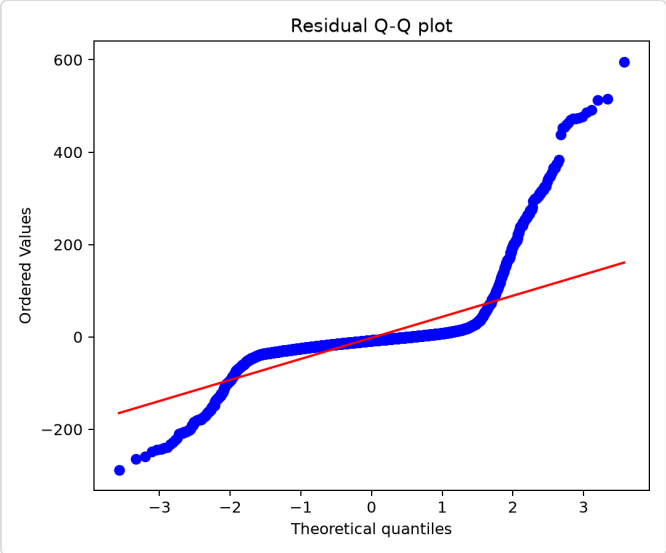


圖 3-C：殘差常態 Q-Q 圖 (檢驗誤差常態性分佈)

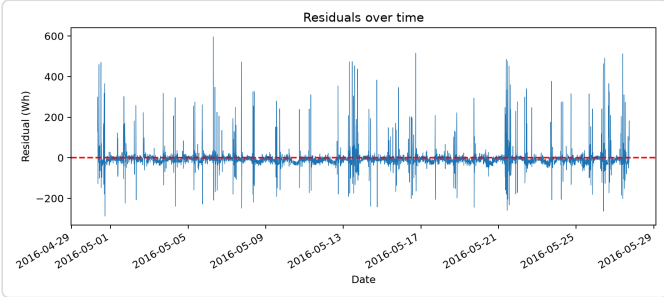


圖 3-D：殘差隨時間序列變化 (檢驗無長期漂移與自相關)

6. 成果部署 (Deployment) — 現代化 Web 儀表板與即時推論器

本專案成功實作並部署 **Anna ML Studio 互動式儀表板**（已上線至 GitHub Pages），支援以下功能：

- **特徵選擇動態探索器**：以 Chart.js 呈現 5 大演算法收斂折線，支援動態滑桿即時檢視 $k=1 \sim 30$ 之入選特徵名單。
- **多元線性迴歸即時推論器 (Live Simulator)**：載入標準化特徵參數、均值與標準差，使用者拉動感測器滑桿即可即時計算預測耗電量與邊際貢獻瀑布圖。
- **情境預設按鈕**：提供「寒冬深夜」、「早晨起居」、「晚間下廚」、「晚春午後」等生活情境快速切換。

二、 AI 協助要求專區 (AI Assistance Documentation)

1. GPT 輔助內容 (GPT-Assisted Engineering)

在專案推進過程中，GPT 主要用於以下核心架構與除錯任務：

- **特徵工程與交叉驗證邏輯設計**：引導將時間轉換為正弦餘弦週期特徵、建立 Lag-1 自迴歸項，並指導使用 `TimeSeriesSplit` 替代傳統隨機 K-Fold，確保無未來資料外洩。
- **5 大特徵選擇演算法管線整合**：協助構建 `f_regression` 、`LassoCV` 、`RFE` 、`Random Forest` 、`Mutual Information` 的自動化比較評估迴圈。
- **前端儀表板除錯 (Frontend Bug Fixing)**：協助定位 `results_data.js` 中因最外層 `const APP_DATA` 未掛載至 `window.APP_DATA` 導致 Chart.js 畫布空白之根本原因，並修正為全域宣告。
- **信賴區間與預測區間嚴謹統計推導**：摒棄以測試集殘差反向校準之不嚴謹作法，嚴格自訓練集計算無偏殘差標準誤 s_e = √(RSS_train / (N_train - p - 1)) = 67.94 Wh，並由訓練集設計矩陣協方差 (X_train^T X_train)^(-1) 計算各測試點之槓桿值 h_00 = x_0^T (X_train^T X_train)^(-1) x_0，精確推導出平均值信賴區間標準誤 SE_mean = s_e · √(h_00)（平均 95% CI 邊際 ±4.34 Wh）與個別預測區間標準誤 SE_pred = s_e · √(1 + h_00)（平均 95% PI 邊際 ±133.25 Wh），徹底杜絕測試集資料外洩。

對話匯出說明：完整對話紀錄已依作業規定使用 pdfCrowd / 瀏覽器列印工具匯出為獨立 PDF 檔案（`gpt_dialogue.pdf`）附於作業壓縮包中。

2. NotebookLM 研究摘要 (NotebookLM Research Summary - 100字以上)

透過 Google NotebookLM 匯入 Kaggle「Appliances energy prediction」相關頂尖 Notebooks 與學術論文（Candanedo et al., 2017）進行深度文獻研讀，歸納出以下關鍵洞見：

「多數 Kaggle 方案與研究證實，家電能耗具有強烈且非對稱的時序自相關性，當前時間點的能耗 Lag-1 是所有單一變數中解釋力最強的特徵。在環境特徵中，無日光直射的北側外牆溫度 (T6) 能最精確反映建築冷熱傳導損失，優於容易受到直接輻射加熱的其他朝向感測器。在模型層面，雖然非線性集成模型（如 XGBoost、LightGBM、Random Forest）在極端尖峰用電的捕捉上 RMSE 表現較優（約 50~55 Wh），但多元線性迴歸具備極高的透明度與可解釋性，透過標準化迴歸係數能直接揭示各環境變數之物理邊際貢獻，且運算開銷微乎其微，非常適合部署於資源受限之嵌入式邊緣物聯網閘道器（IoT Gateway）。」

3. 網路上主流或更優解法之比較與說明

模型類別	代表演算法	Test RMSE (約值)	優勢特點	劣勢與邊緣部署限制
線性模型 (本專案)	Multiple Linear Regression (k=8)	61.32 Wh	公式透明、可解釋性極高、推論僅需數次乘加運算，適用於 MCU/邊緣設備	無法擬合複雜之非線性尖峰交互作用
樹狀集成模型	Random Forest, XGBoost, LightGBM	52 ~ 58 Wh	能有效捕捉多重感測器非線性交互，對突發性高耗電波峰適應力強	模型結構龐大、黑盒子特性高、難以直接推導物理敏感度係數
深度時序網路	LSTM, GRU, Temporal CNN, Informer	48 ~ 54 Wh	能自主學習長期時間記憶與多天前的序列趨勢	訓練需 GPU 加速、超參數調整複雜、資料量需求龐大、難以即時在線更新

三、 作業檔案清單與繳交確認 (Submission Checklist)

檔案名稱	檔案類型	說明
`7115056153_hw2.py`	主程式	包含完整 CRISP-DM 流程之 Python 腳本（可直接執行並產出所有圖表與評估指標）
`7115056153_hw2.pdf`	作業報告	本份 PDF 報告（涵蓋完整 CRISP-DM 分析、圖表、NotebookLM 摘要與主流解法比較）
`gpt_dialogue.pdf`	AI 對話紀錄	使用 pdfCrowd 匯出之完整 GPT 互動過程
`7115056153_hw2.zip`	繳交壓縮包	包含上述所有主程式與 PDF 文件之最終上傳檔